

西安交通大学

硕士学位论文

基于无源域适应的毫米波动作识别方法研究

学位申请人：郑正正

指导教师：冯峰教授

学科名称：航空宇航科学与技术

2024 年 03 月

English Title and English Title and English Title

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Zhengzheng Zheng
Supervisor: Prof. Feng Feng
Aeronautical and Astronautical Science and Technology
March 2024

硕士学位论文答辩委员会

基于无源域适应的毫米波动作识别方法研究

答辩人：郑正正

答辩委员会委员：

西安交通大学教授：张长长_____（注：主席）

西安理工大学教授：王旺旺_____

国网陕西经济技术研究院高工：李力_____

西安交通大学副教授：东方不败_____

西安交通大学研究员：赵照_____

答辩时间：2021 年 06 月 22 日

答辩地点：西安交通大学主楼 E 座 303 室

摘 要

随着毫米波技术的发展和人们对日常生活各方面需求的进一步提高，基于深度神经网络的毫米波感知在动作识别等方向得到了广泛运用，而域适应可以利用已有含标签的数据克服不同反射环境对深度网络感知效果的负面影响。而当下对于个人隐私的高度重视也对该技术提出了新的挑战。因此，无源域适应的毫米波动作识别技术具有非常重要的实用价值。

本文研究了基于无源域适应的毫米波动作识别技术，用于智慧家庭设备、医院患者检测、商场购物结算等场景下的动作感知任务。该方法利用深度学习方法，在只获取含标签数据训练后的网络模型的前提下，通过学习训练集数据表征对模型进行微调，从而在提升模型不同反射的环境中对动作的识别精度。本文的主要研究内容有两个方面：

1) 提出了面向多环境数据辅助单目标环境动作识别场景的基于联邦学习方式的域适应方法。首先在本地分别用不同环境下含标签数据训练模型，然后将各模型参数上传至云端对目标环境数据进行分类预测，通过投票机制确定本地各环境模型的贡献度，从而进行参数聚合得到符合目标环境的动作识别模型。该方法可以更好地利用到多环境的优势进行远端联合建模，且保证了数据的隐私性。

本文在不同环境下自行采集的毫米波数据中开展了大量实验，并与该领域相关的工作进行了比较分析。结果表明，本文所提出的方法在不使用已知环境数据的条件下，能够利用调整模型参数的方式直接完成域适应目标，提高目标环境下的动作识别精度，并且在评估指标方面好于基准方法，证明了方法的有效性。

本文做出了以下贡献：

关 键 词：无线感知；动作识别；深度学习；无源域适应

论文类型：应用探究

* 本研究得到某某基金（编号：）的资助

ABSTRACT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

1. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper,

*The work was supported by the Foundation (foundation ID).

felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

3. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

KEY WORDS: MHD equations; Finite element methods; Decoupled scheme; Stability; Convergence; Structure preserving; Preconditioning method

TYPE OF THESIS: Theoretical Research

目 录

声明

CONTENTS

Declarations

1 绪论

1.1 研究背景及意义

物联网（IoT）技术的发展标志着智能设备和系统互联的新时代。通过无线感知技术，如 RFID、毫米波、蓝牙和 Wi-Fi，物联网设备能够感知环境变化、收集数据并进行通信，实现自动化管理和智能化操作。随着 5G 网络的推出和边缘计算、人工智能技术的进步，物联网的数据处理和分析能力得到极大增强，推动了其在众多领域的广泛应用。物联网和无线感知技术的结合不仅提高了生活和工作的便利性，还为解决复杂问题和推动创新开辟了新途径。未来，随着技术的不断进步和应用标准化的推动，物联网预计将实现更深入的集成和广泛的应用，为社会经济发展带来深远影响。

无线感知技术作为物联网技术的关键感知手段，随着无线通信技术的快速发展和智能设备的广泛应用，也取得了显著进展，基于毫米波的动作识别技术^[1]就是其中一个重要的分支：毫米波雷达发射和接收电磁波，捕获目标对象的动作信息。雷达信号在遇到对象时反射，通过分析这些反射信号，可以提取出动作特征。然后，利用信号处理技术，将这些特征转化为可分析的形式。最后，采用机器学习或深度学习算法对特征进行分类或识别，实现对特定动作的准确识别。这项技术具有许多优势：与传统的接触式传感器监测和识别技术相比，基于毫米波的动作识别技术不需要与人体直接接触，减少了传染病的传播风险，也提高了被感知用户的便捷性和舒适性。同时，毫米波雷达能够穿透烟雾、尘埃等环境，即使在视线受阻或光线不足的情况下也能准确识别动作，这使得它在复杂或恶劣环境下具有出色的适用性。毫米波雷达对于对象速度和距离的精准测量，也保证了动作识别的高度准确性。得益于上述方面的显著优点，毫米波动作识别领域产生了许多结合实际情景的优秀工作^[2-4]，并展现出巨大的应用潜力和社会价值：

健康监测和医疗保健：在医疗保健领域，基于毫米波的动作识别技术可以用于患者的跌倒监测，以及康复训练的辅助等，帮助医生远程监测患者的康复进度，这对于提高医疗服务质量和效率都具有重要意义。

智能家居与办公自动化：在智能家居系统中，基于毫米波的动作识别可以实现远程控制家电、灯光和安全系统等，提高生活便利性和舒适度。在办公自动化领域，该技术可以用于会议室的自动管理、能源的高效使用等。

公共场所非接触人机交互：在商场等场所中，基于毫米波的动作识别可以实现无接触操作，在流行性疾病爆发时，可以有效减少因触碰公共设施而感染病毒的风险。在新冠疫情爆发后，这些处于卫生健康方面的举措更加值得被注意与参考。

尽管基于毫米波的动作识别技术具有众多优势，但它也存在一些局限性和挑战，其

中环境问题最为关键。虽然毫米波雷达能够穿透某些物质，但它仍然可能受到环境因素的干扰，如多径效应（信号反射造成的干扰）、湿度和温度变化等，这些因素可能会影响系统的性能和准确性。

深度学习领域中的域适应技术被认为是一种克服模型对于特征分布存在差异的数据预测结果失准问题的方法，对应在无线感知的问题设置下，已知环境对象的数据被称为源域，需要识别的环境对象数据被称为目标域。该技术通常涉及到一些手段，让模型能够学习到数据中更为普遍、本质的特征。域适应最初主要用于计算机视觉领域，目前也被证明在毫米波动作识别领域具有作用，近年来许多相关工作都被提出。但这些工作大都需要获取一定源环境含标签的数据参与模型训练。尽管毫米波动作识别技术不捕捉人体面部或身体细节，从而在一定程度上保护了用户的个人隐私，但它仍然能够收集关于个人行为 and 习惯的敏感信息。例如，个人的行为模式、日常活动习惯甚至健康状况都可能通过动作识别技术间接获得，引发用户对于隐私问题的担忧。同时，如果这些敏感数据未经加密或在没有足够安全措施的情况下被传输和存储，也存在着被黑客攻击窃取和数据泄露的风险，可能导致数据遭到未经授权的访问或滥用。如果缺少源环境数据，将缺乏对不同环境之间数据差异的直观度量，导致传统的域适应方法的性能大幅度下降。

为了解决上述问题，本文提出了一种基于无源数据域适应的毫米波动作识别方法。该方法将域适应的侧重点放在对目标环境数据自身所包含特征信息的无监督学习上。针对动作识别的实际场景对域适应方法实现的要求，分布设置不同的处理策略，在不直接利用已有环境数据的条件下，利用联邦学习、伪标签等方法调整目标环境模型参数，改善模型在目标识别环境上的性能。因为目前缺乏公开的毫米波人体动作数据集，同时出于对实际应用意义的考虑，本文在自主实验收集的多个环境下若干名志愿者的毫米波动作数据集上进行了实验，验证了所提出方法的有效性。同时本文与相关领域其他方法进行了对比实验，体现出本方法的优势。

1.2 国内外研究现状

本文涉及的无源数据域适应技术主要涉及深度学习的内容。随着深度学习技术的发展，计算机视觉领域各种问题场景下的相关技术方法都已非常成熟。目前被提出的许多涉及跨场景无线感知方向的工作也都受到这些方法的影响，但这些工作中缺乏了缺乏源域数据的情况下对多环境跨域动作识别任务的研究。下面将从分别从计算机视觉域适应和无线跨场景感知两个领域方向陈述国内外相关研究现状。

1.2.1 基于视觉的域适应

作为一项最初主要用于解决视觉领域的技术，域适应目前更多采用深度学习作为解决不同领域之间差异问题的方法。然而现实应用场景对模型的训练数据提出更严格的要求：许多情况下不同领域的数据并不满足独立同分布的条件，同时视觉领域一些场景的数据集往往很难获得标注导致了許多数据缺乏对应标签，这些问题超出了传统方法的假设范围^[5]，对预测性能提出了挑战。为了应对这种情况，近年来许多相关研究人员都以无监督形式为主要方向。在这种问题设置中，深度模型利用一个领域的数据集进行训练，但需要在所有标签未知的领域数据集上进行预测，通过特征表示的转换、对抗性训练等技术来找到一种对领域偏移不敏感的表征方法，从而提升模型在未知数据上的泛化能力。Xu 等人^[6]利用了深度学习领域的混合（Mixup）方法，将源域与目标域数据进行线性插值实现数据增强，提高模型在目标域的泛化能力。Zhu 等人^[7]在生成对抗网络的基础上，设计循环对抗神经网络（CycleGAN）通过额外添加逆向映射关系，试图在保留图片内容结构的基础上学习新的图片风格，过程中引入了循环一致性约束确保对两种映射的训练是一致的。Yang 等人^[8]首次尝试使用 Vision Transformer 解决无监督域适应任务，并加入可迁移学习模块同时捕获迁移性特征和判别性特征，提升模型迁移能力。

许多无监督域适应工作也从半监督学习中获得指导，着眼于对特征空间对齐以外的探索，例如对伪标签、熵最小化等方法的应用。伪标签即使用当前模型为目标域不可知的数据预测，经置信度判别后生成伪标签，从而与源域数据共同参与模型训练。Han 等人^[9]利用余弦相似度作为指标为目标域样本特征计算类聚类中心，之后计算各样本与中心的余弦相似度，将最小值所对应中心类别作为该样本的伪标签。可以看出，该方法的精度对伪标签本身的准确性很高，不准确的伪标签可能会给模型学习带来灾难性的误差。熵最小化利用损失约束模型的预测更自信，即熵值更低。Jin 等人^[10]提出了一种域适应任务通用的最小类混淆损失函数（MCC）以训练模型分类器混淆对目标域上正确类和模糊类之间的预测的趋势，关注模型预测类别的确定性。这类方法存在过度信赖自信但不准确的模型而影响性能的风险。同时，和传统设置的无监督方法一样，这些方法缺乏对于没有源域数据场景跨域任务的处理手段。

随着视觉领域的发展，域适应技术在处理不同特定问题的过程中也出现了新的趋势。现代技术发展对于隐私保护的重视程度一直在提高，尤其是医疗等严格遵守隐私条例、数据传输约束或数据专有化的场景，标记的数据通常受到限制。这需要考虑到在无法获得源域数据的前提下探索将不同领域数据表征进行对齐的可能性。Liang 等人^[11]利用了半监督学习的算法，提出在预训练完成后固定模型分类器，通过信息最大化损失函数微调特征提取器、对数据标记伪标签的方式提升模型泛化性能。Xia 等人^[12]提出设置多分类器区分数据样本所属领域，利用自适应对抗推理和对比类别匹配的方式在多

分类器和特征生成器之间建立对抗关系，使模型学习到符合多分类器边界的域无关特征。Ding 等人^[13]将源域模型分类器的权重向量作为锚点，在源域数据符合类高斯分布的假设下，利用锚点与目标域数据的均值与协方差模拟构建源域特征分布，采用对比域差异的损失函数（CDD）显式地将不同域的数据在特征空间对齐。然而，在实际动作识别的场景下，会需要同时涉及多个环境的数据同时进行训练，许多无源域适应算法无法应对这种情况的挑战。

1.2.2 基于无线的跨域感知

环境对无线信号有显著影响，包括信号强度的衰减、信号路径的多样化以及外部干扰的介入。环境中的障碍物如墙面和金属物体等能够吸收和反射无线信号，导致信号弱化。移动中的物体，如人，会改变信号的传播方向，造成多径效应，对接收信号的稳定性造成影响。同时，其他电磁源的存在可能引起信号干扰，进而降低通信效率。因此，在设计无线通信系统时，必须考虑到这些环境因素，以保证通信的可靠性和效率。但在实际情况下，无法保证每个感知场景都符合信号传播的理想条件，这导致了采集到的无线信号包含了大量环境的噪声。因此，在不同的环境下会获得具有不同特征的信号数据。同时，无限感知领域缺乏视觉领域中具有一定规模的跨域数据集^[14-16]，考虑到现实中无线信号采集带来的较大时间开销，在所有环境都进行大量数据收取无疑是不合理的。研究人员针对无线感知的跨场景问题也做了很多探究，目前主要通过信号处理和域适应的方法处理该问题。

1) 基于信号处理的跨场景感知

该类方法主要通过对获取信号中的信道状态信息（CSI）预处理以提取数据中与环境无关的特征进行学习，从而克服无线感知过程中存在的环境依赖问题。Tan 等人^[17]利用时频域变换、离散小波变换的方式消除了 CSI 中部分与环境有关的噪声，同时通过找寻同一分类数据最佳对齐作为数据的主要特征以识别手势动作。Yang 等人^[18]通过类估计基空间奇异值分解（CSVD）的方法对 CSI 进行重构消除部分环境信息，再采用非负矩阵分解（NMF）获取各类数据的特征分布以进行活动识别任务。Li 等人^[19]从多普勒频移和 CSI 中包含的幅度、相位差信息中获取了丰富特征共同作为输入从而对活动进行分类预测。基于信号处理的工作给之后的工作提供了许多数据层面上环境因素消除的方法参考。然而它们对环境依赖的消除是有限的，还需要从学习特征的方面进行研究以提高整体精度，同时部分方法也存在设备复杂、难以部署的问题。

2) 基于域适应的跨场景感知

该类方法从深度学习中的域适应技术着手，训练模型学习经预处理的无线信号数据中包含的域无关特征。Jiang 等人^[20]基于对抗的思路设计了环境无关框架 EI，由特征

提取器和两个分类器组成，其中分类器分别用于判别样本对应的人类活动种类和环境领域。Ding 等人^[21]提出了由双路径基础网络和基于度量的元学习框架组成的 RF-Net。前者将空间模块与基于注意力的时间模块相结合，用于从时域和频域学习数据包含的时空特征，后者则通过特定的射频参数模块训练准确的距离度量，从而提升模型在新环境下的泛化能力。Bhalla 等人^[22]利用了较为广泛的智能手表 IMU 公开数据集，通过多模态数据的高维特征对齐完成了毫米波雷达传感器的活动识别系统 IMU2Doppler。Zhou 等人^[23]受到半监督学习的启发，提出了基于不确定性的内集划分方法，通过与元学习相结合来更好利用被标记的样本，同时引入一种动态伪标签策略，将目标域未标记样本纳入训练。然而目前的方法大都是在源域数据可用的基础上进行设计的，这无法满足许多场景对于数据隐私保护的实际需要。采用多模态迁移的 IMU2Doppler 则更多展示了该类方法的应用可能性，它的预测精度与其他的无线感知工作相比有一定的差距。

1.3 论文研究内容

本文主要研究内容为基于无源域适应的毫米波动作识别方法研究，在现有的域适应和无线感知方法的基础上，结合毫米波动作识别在实际应用中存在的隐私问题和多方合作问题进行了研究。

本文的研究内容主要分为以下两点：

1) 提出了面向多环境数据辅助单目标环境动作识别场景的基于联邦学习方式的域适应方法。首先在本地分别用不同环境下含标签数据训练模型，然后将各模型参数上传至云端对目标环境数据进行分类预测，通过投票机制确定本地各环境模型的贡献度，从而进行参数聚合得到符合目标环境的动作识别模型。同时考虑到多源域情况下各个环境数据来源丰富，在进行联邦学习的过程时也需要注重对模型预测的普适性的提升，因此本方法又设计了一种源域域适应模块在一定程度上提升源域模型对自身数据的预测精度。该方法可以更好地利用到多环境的优势进行远端联合建模，且保证了数据的隐私性。

2)

以上两个研究内容在自行采集的毫米波数据集上进行了大量的实验，验证所提出的毫米波动作识别方法的有效性，并于其他相关技术进行了对比分析，证明了本文所提出方法的优势。

1.4 论文组织结构

本文将分五个章节对研究内容进行介绍，具体如下：

第一章为绪论部分。首先确定基于无源域适应的毫米波动作识别方法研究的研究背景与意义，其次对国内外视觉领域域适应技术和无线领域跨域感知技术的发展现状进行了总结概括，分析了当前方案的特点和存在的局限，进一步说明了本文的研究意义。最后。对本文的本文的主要研究内容进行了简要描述。

2 相关理论技术

2.1 毫米波通信原理及数据处理方法

毫米波是一种介于紫外线和微波的电磁波，波长范围为 1 毫米到 10 毫米，频率大约为 30 到 300 吉赫（GHz）之间。较短的波长意味着毫米波设备能够将大型天线阵列封装在较小的物理尺寸中，极宽的高频带宽确保毫米波通信在密集的频谱条件下具有相当的吸引力^[24]。

2.1.1 毫米波雷达通信原理

毫米波雷达是一种使用毫米波段的电磁波来探测和测量目标的雷达系统，这种雷达被广泛应用于目标检测^[25]、自动驾驶^[26]、航空监视^[27]等领域。利用其进行感知的通信过程主要如下：

信号发射过程：毫米波雷达通过自身的发射装置生成高频率的电磁波。这些波按照确定的频率和相位发射，能够穿过大气层并向前扩散。

物体探测机制：在毫米波雷达释放的电磁波与路途中的物体（比如汽车、步行者或其它障碍）相遇时，这些波会被物体反射。反射波的特征，包括它们的方向和强度，会根据碰撞物的种类和形状有所不同。

接收反射信号：雷达的接收捕捉到上述过程中被反射回来的部分毫米波信号。因为发射信号的原始属性（如频率和相位）是已知的，所以通过对这些信号进行分析，可以推断出反射体的关键信息。

信号的分析与处理：雷达系统内置的信号处理器对捕获到的反射信号进行解析。通过对比发射的原始信号与收到的反射信号，该系统能够估算出物体的位置（通过计算信号的往返时长）、移动速度（依据多普勒效应，即频率变化），以及物体的方向（通过观察信号的入射角度）。

2.1.2 毫米波数据处理方法

1) 距离测量方法

目前使用的毫米波雷达多为调频连续波雷达，其发射的调频连续波信号的瞬时频率随时间呈现线性的频谱变化趋势，这种信号被称为调频连续波（FMCW，也被称为啁啾信号或者 chirp 信号）。如果 chirp 信号的载频为 f_c ，带宽为 B ，发射时宽为 T_c ，那么在单个 chirp 周期内发射天线 Tx 的信号如公式（2-1）所示：

$$S_{Tx}(t) = A_{Tx} \exp \left(j \left(2\pi f_c t + \pi k_s t^2 \right) \right) \quad t \in (0, T_c) \quad (2-1)$$

式中： A_{Tx} ——发射信号振幅； j ——虚数信号； k_s ——调频率。

假设目标与雷达之间的距离为 R , 那么在经过了时延后, 接收天线 Rx 的回波信号如公式 (2-2) 所示:

$$S_{Rx}(t) = A_{Rx} \exp \left(j \left(2\pi f_c (t - \tau) + \pi k_s (t - \tau)^2 \right) \right) \quad t \in (0, T_c) \quad (2-2)$$

式中： A_{Rx} ——回波信号振幅。

通过混频器对回波信号和发射信号进行处理后得到如公式 (2-3) 所示的中频信号 S_{IF} :

$$S_{IF}(t) = A_{IF} \exp \left(j \left(2\pi k_s f_c t \tau + 2\pi f_c \tau - \pi k_s \tau^2 \right) \right) \quad (2-3)$$

可以看出, S_{IF} 频率受到回波时延调制, 表示如下:

$$f_{IF} = k_s \tau = \frac{2k_s R}{c} \quad (2-4)$$

式中： c ——光速

经过快速傅里叶变换 (Fast Fourier Transform, FFT) 后, 目标物体与雷达之间的距离可以被表示为:

$$R = \frac{c f_{IF}}{2k_s} = \frac{c f_{IF} T_c}{2B} \quad (2-5)$$

可以看出, 利用 FFT 可以从中频信号中获取目标和雷达之间的距离, 因此该变换也被称为距离 FFT (Range-FFT), 其对于提高雷达成像的分辨率和准确性有重要意义, 特别是在合成孔径雷达 (SAR) 成像中, 距离傅里叶变换用于处理雷达沿着其飞行路径接收到的连续信号, 以生成地面目标的高分辨率图像。

假设信号的采样频率为 f_s , 采样数量为 N , 根据奈奎斯特采样定律可知, 复数信号的采样频率至少需要大于采样信号的最大频率。由此可知, 毫米波雷达最大的不模糊估计距离为:

$$R_{\max-\text{analog}} = \frac{c f_{IF-\max} T_c}{2B} \leq R_{\max-\text{digital}} = \frac{c f_s T_c}{2B} \quad (2-6)$$

然而, 在实际毫米波测量的情况中, 最大不模糊距离值受限于负频谱的存在只能达到理论值的一半, 如公式 (2-7) 所示:

$$R_{\max} = \frac{cf_s T_c}{4B} \quad (2-7)$$

对于信号来说，当整段距离的采样总数为 N_s 时，距离分辨率可表示如下：

$$R_{\text{res}} = \frac{R_{\max-\text{digital}}}{N_s} = \frac{cf_s T_c}{2BN_s} \quad (2-8)$$

2) 速度测量方法

目标的速度可以利用多个中频信号经 Range-FFT 和时频域变换处理后的相位差异观测出^[28]。通信过程中，将 N_c 个具有相同的发射时宽的一系列 chirp 信号被称为帧。则在一个帧周期之中，chirp 信号的频率随时间变化情况如图 2-1 所示。



图 2-1 一个帧周期内 chirp 信号的频率变化图

当一个帧周期内有 N_c 个 chirp 信号被发射，那么对于第 i 个中频信号，其相位 ϕ_i 可被表示为公式 (2-9)：

$$\phi_i = 2\pi \left(f_c \tau_i - \frac{1}{2} k_s \tau_i^2 \right) \quad i \in (1, N_c) \quad (2-9)$$

毫米波雷达感知的目标移动速度一般小于 10^2 ，然而一个帧周期时间的数量级大约为 10^{-4} ，因此在该帧周期内可以将目标移动速度视为恒定值，同时目标的移动距离不会大于雷达最小距离分辨率。则对于第 i 个回波，满足：

$$\tau_i = \frac{2(R_1 + v(i-1)T_c)}{c} \quad (2-10)$$

式中： v ——该帧周期内目标物体的移动速度； R_1 ——该帧周期内收到第一个回波时目标物体与雷达的距离。

由公式 (2-9) 和公式 (2-10) 可知：

$$\phi_i = 2\pi \left(\frac{2(R_1 + (i-1)vT_c)f_c}{c} - \frac{2k_s(R_1 + (i-1)vT_c)^2}{c^2} \right) \quad (2-11)$$

其中 c^2 项可忽略，故可得到：

$$\phi_i = 2\pi \left(\frac{2(i-1)vT_cf_c}{c} + \frac{2R_1}{c} \right) \quad (2-12)$$

经过 Range-FFT 后，可观察到该帧周期内所有 chirp 的中频信号在同一距离上出现的峰值复包络能够组成新的复信号序列，其相位变化可以表示为：

$$S_{\text{doppler}}(\phi_i) = A_{\text{doppler}} \exp(j \cdot \phi_i + \phi_{\text{doppler}}) \quad (2-13)$$

式中： ϕ_{doppler} ——该复信号序列初始的相位

其中，复信号序列的中心频率与目标物体速度相关。该信号序列的中心频率可以在每个 chirp 的发射时宽为单位微分获得，如公式所示：

$$f_v = \frac{1}{2\pi} \cdot \frac{\partial \phi_k}{\partial (iT_c)} = \frac{2vf_c}{c} = \frac{2v}{\lambda} \quad (2-14)$$

式中： λ ——波长

由公式 (2-14) 可知，对新产生的复信号序列进行 FFT 所得频域数值即为该距离单元目标的移动速度，因此该变换也被称为多普勒 FFT (Doppler-FFT)。Doppler-FFT 结合了多普勒效应的原理和 FFT 的计算效率，能够实时地处理大量数据，为雷达系统提供精确的速度度量。

由公式 (2-12) 可知，两个相邻的 chirp 回波的相位差可表示为：

$$\Delta\phi = 2\pi \left(\frac{2vT_cf_c}{c} \right) = \frac{4\pi vT_c}{\lambda} \quad (2-15)$$

则目标的移动速度如下所示：

$$v = \frac{\lambda \Delta\phi}{4\pi T_c} \quad (2-16)$$

速度测量方法是利用相位差推导所得，考虑到数字信号处理中相位差存在不模糊区间，需要满足 $\lambda \Delta\phi$ 小于 π ，结合公式 (2-16) 可推导出 $v < N/4T_c$ 。则雷达可测得目标最大的不模糊速度如公式 (2-17) 所示：

$$v_{\text{max}} = \frac{\lambda}{4T_c} \quad (2-17)$$

当同一位置存在两个移动且速度不同的目标，在接收各个目标反射的同一帧内的 N_c 个 chirp 信号的回波后，通过 Range-FFT 的处理生成了同等数量个具有相同距离的峰值的频谱图，图中的峰值均有不同的相位，且这些相位包含了两个目标的相位分量。提取所有频谱图中峰值位置的相位，并对 N_c 个向量进行 Doppler-FFT 会获得两个存在不同峰值的新频谱图，而峰值对应应在图中的横坐标即为这两个物体的相位差，如图 2-2 所示。



图 2-2 Doppler-FFT 后产生的信号频谱图

若两个物体的速度分别为 v_1 和 v_2 ，反射的 chirp 信号相位差为 ω_1 和 ω_2 ，则由公式 (2-16) 可得：

$$v_1 = \frac{\lambda \omega_1}{4\pi T_c}, v_2 = \frac{\lambda \omega_2}{4\pi T_c} \quad (2-18)$$

其中， ω_1 和 ω_2 需满足 $\Delta\omega_1 = \omega_2 - \omega_1 > 2\pi/N$ 才能确保二者被分开。当一帧内有 N_c 个信号回波时，可推导出雷达的速度分辨率如公式 (2-19) 所示：

$$v_{\text{res}} = \frac{\lambda}{2N_c T_c} \quad (2-19)$$

3) 角度测量方法

本文在感知人体动作过程中使用了 TI 所生产的 AWR1443BOOST 雷达，包含了 3 个发射天线和 4 个接收天线。图 2-3 展示了在感知过程中该种毫米波雷达的天线排布情况以及等效转化的等效虚拟阵列。假设位于同一水平线的发射天线 Tx1 和 Tx3 之间距离为 2λ ，发射天线 Tx2 位于二者中央正上方且垂直方向距离为 $\lambda/2$ ，所有的接收天线均在同一水平线等距排布且相邻天线的距离为 $\lambda/2$ 。这样的排布方式使转换的等效虚拟阵列存在特殊的规律。在虚拟阵列中，发射天线 Tx2 与接收天线所组成的 4 个虚拟阵元位于中央正上方，Tx1 和 Tx3 与接收天线组成的虚拟阵元在下方按从左到右的顺序排列。其中，所有位于同一水平线的相邻虚拟阵元距离为 $\lambda/2$ ，上方阵元与下方阵元

的垂直距离也为 $\lambda/2$ 。



图 2-3 毫米波雷达天线排布及等效虚拟阵列示意图

以该类型雷达为例，在感知目标的过程中，假设以雷达为原点构建空间坐标系，目标相对于雷达的位置坐标为 (x, y, z) ，与雷达之间距离为 R ，相对雷达的方位角为 φ ，俯仰角为 ϕ 。该空间位置情况如图 2-4 所示。



图 2-4 毫米波雷达天线排布及等效虚拟阵列示意图

由三角函数可推导出目标位置信息包含如下关系：

$$\begin{cases} z = R \sin \phi \\ x = R \sin \phi \cos \varphi \\ y = \sqrt{R^2 - x^2 - z^2} \end{cases} \quad (2-20)$$

考虑到感知目标多为远场，则对于不同的虚拟阵元，同一信号回波与其方向均可视为平行。由此可以推导出垂直方向上相邻虚拟阵元信号回波因俯仰角导致的相位偏

移 w_z 如公式 (2-21) 所示:

$$w_z = \frac{2\pi}{\lambda} \cdot \frac{\lambda}{2} \cdot \sin \phi = \pi \sin \phi \quad (2-21)$$

基于相同原理, 水平方向上相邻虚拟阵元信号回波因方位角导致的相位偏移 w_x 如公式 (2-22) 所示:

$$w_x = \frac{2\pi}{\lambda} \cdot \frac{\lambda}{2} \cdot \sin \phi \cdot \cos \phi = \pi \sin \phi \cos \phi \quad (2-22)$$

由此可知, 对于同一信号而言, 下方的虚拟阵元的相位变化可组成新的信号序列 S_1 。该序列的中心频率响应就是方位角的相位偏移 w_x , 如公式 (2-23) 所示:

$$S_1(m) = A_1 \exp(j \cdot (w_x(m-1) + \psi)) \quad (2-23)$$

式中: m ——阵元序号; ψ ——该信号序列的初始相位。

对上述信号序列进行 FFT 处理后可以获得 w_x , 从而获得到达角, 因此该变换也被称为角度 FFT (Angle-FFT)。

若对该序列进行 Angle-FFT 处理后, 其频率最大响应对应的横坐标是 n_{\max} , 可得:

$$w_x = \frac{2\pi n_{\max}}{N} \quad (2-24)$$

式中: N ——信号序列数量。

亦可得到该频率最大响应的峰值 P_1 表示如下:

$$P_1 = A_1 e^{j\psi} \quad (2-25)$$

上方虚拟阵元相位变化的信号序列 $S_2(m)$ 则为:

$$S_2(m) = A_2 \exp(j \cdot (w_x(m-1) + \psi + 2w_x - w_z)) \quad (2-26)$$

则该频率最大响应的峰值 P_2 表示如下:

$$P_2 = A_2 e^{j(\psi + 2w_x - w_z)} \quad (2-27)$$

将两个信号序列的共轭相乘, 得到公式 (2-28):

$$P_1 P_2^* = A_1 A_2 e^{j(w_z - 2w_x)} \quad (2-28)$$

由此可得 w_x 的表达式如下：

$$w_z = \angle \left(P_1 \cdot P_2^* \cdot e^{j(2w_x)} \right) \quad (2-29)$$

结合公式 (2-20) 和 (2-22)，即可获得目标相对于毫米波雷达的空间位置信息。

2.2 深度学习网络

本文使用深度学习网络来获取经信号处理后的毫米波频谱图中包含的特征信息，从而学习判别人体不同的动作。本文参考了深度学习领域的优秀网络架构。在本小节中，将对这些架构的基本原理进行具体介绍。

2.2.1 卷积神经网络

深度学习中的神经网络 (Neural Network, NN) 是研究人员受到人脑工作机制的启发，被设计用来识别复杂的模式和数据关系的算法。卷积神经网络 (Convolutional Neural Network, CNN) 在神经网络的基础上，引入了对数据的卷积操作，使网络对特征学习更加有效。

CNN 主要由卷积层、激活层、池化层、全连接层等组成。毫无疑问，卷积层为 CNN 的核心部分。在该层中，利用与预设好大小的卷积核在输入数据上按一定步长滑动，在每个位置上将卷积核与其覆盖的数据部分对应元素相乘运算，然后求和，该过程被称为卷积。以图像 x 为例，卷积核 w 对其进行卷积操作的过程可以表示如下：

$$y(m, n) = (x * w)(m, n) = \sum_{i, j} x(i, j) w(m - i, n - j) \quad (2-30)$$

式中： m ——卷积核中心所处图像的行位置； n ——卷积核中心所处图像的列位置。

运算过程中，卷积核感知的区域被称为感受野，该机制能够使卷积核对数据不同位置的空间局部特性加以利用，从而提取出高阶特征。滑动中的卷积核也学习到数据可能存在的平移不变性，以一张二维图像为例，当对图像做旋转，翻转等操作，卷积核依然能准确识别图像的类别。同时相较于传统的全连接层，卷积核的复用机制极大减少了网络训练过程中的参数量。激活层通常设置在卷积层后，利用非线性映射函数增加模型的非线性特性，从而提升网络学习复杂模式的能力和加快网络学习速度，该类函数也被称为激活函数。池化层通过对数据在不同位置上卷积运算后获取的信息进行整合过滤，从而降低了特征的尺寸和模型参数数量，理想的池化操作注重丢弃不相关细节，保留重要的信息^[29]。全连接层一般位于网络末端，将对网络所学习的特征映射到最终的分类结果上。

CNN 通常还会利用批归一化^[30] (Batch Normalization, BN) 和 Dropout^[31] 操作。BN 主要被用来解决网络中参数更新导致的内部协变量偏移问题, 加快训练速度。该方法主要分为两步: 首先计算每个小批量数据的均值和方差, 利用这些数值对数据进行标准化操作, 接下来利用可学习参数缩放和平移标准化的数据。Dropout 被用来解决神经网络在学习过程中因学到许多相互适应的非线性关系连接而出现的过拟合问题, 通过在训练时随机丢弃或暂时移除网络中的部分单元迫使网络学习更具鲁棒性的特征, 提高模型泛化能力。

LeCun 等人^[32]提出的 LeNet-5 虽受限于当时的硬件发展问题, 与传统机器学习方法相比并未显示出性能的优越性, 但是确立了 CNN 的网络结构, 为当今的神经网络设计奠定基础。随着通用 GPU 的兴起和深度学习理论的提出和发展, 卷积神经网络在研究人员后续产出的工作中不断提升了性能。

Alex 等人^[33]提出的 AlexNet 是 CNN 在大规模图像识别任务上的首次成功应用, 在 2012 年 ImageNet 挑战赛中大幅度超越其他参赛模型的性能, 该网络在 LeNet 的基础上进行了拓宽和延申, 整体由 5 个卷积层、3 个全连接层组成, 并且创新性地使用了 Relu 激活函数, 全连接层 Dropout 策略和多 GPU 训练技术。AlexNet 的成功证明了深层网络可以有效处理复杂图像任务, 标志着深度学习在视觉领域取得重大突破。

Simonyan 等人^[34]提出了 VGG 网络架构, 就深度对性能的影响进行了探索。该网络设计具有分层和模块化的特点, 使用了较 AlexNet 更小的卷积核, 从而使网络深度达到了 19 层。VGG 验证了小尺寸卷积核通过堆叠也可以达到近似大尺寸卷积核的效果, 其结构理念推动了之后的深度神经网络设计发展, 使采用小尺寸卷积核成为了未来构建网络的主流选择。

Lin 等人^[35]提出的 NIN 利用在传统的卷积层中嵌入微型网络的方式代替传统卷积运算, 在帮助网络学习到更复杂的特征的同时显著减少了参数量。NIN 给出了一种不同于简单层叠卷积网络的新颖思路, 为后续网络设计提供了方向。

Szegedy 等人^[36]设计了 GoogLeNet, 其核心模块 Inception 的引入允许网络在每个模块中自适应地选择多种大小的卷积核增加网络宽度, 多尺寸卷积核的使用也有效地捕捉到不同尺度上的特征, 从而进一步提升了特征包含的信息量。

许多对增加深度提高网络学习能力的工作为领域内研究人员开拓了探索道路。然而模型不断加深也带来了许多挑战, 例如显著提升模型收敛难度, 大幅增高了训练开销等, 这些问题一度导致了深度学习发展的停滞。He 等人^[37]提出了 ResNet。通过引入残差模块, ResNet 允许构建更深的网络架构而不会增加训练的难度。这些模块中的跳跃连接直接将输入连接到输出, 确保了梯度可以顺利地在网络中传播, 有效解决了深度神经网络训练中的梯度消失问题。ResNet 显著提升了深度卷积模型在多个视觉任务上的性能, 其出现也推动了自然语言处理等领域对网络设计思路的创新, 对深度学习

的发展产生了深远影响。

2.2.2 Transformer 模型

注意力 (Attention) 机制是一种独特的人类大脑处理机制，特别体现在视觉系统中。通过对整体图像进行快速浏览，人类能够识别出需要集中关注的特定区域。随后，大脑会将更多的注意力资源分配到这个区域，以便深入挖掘目标的详细信息，同时忽略其他不相关的信息。深度学习领域的 Attention 机制保留了核心理念，以选择出对当前任务目标更关键的信息为关键目标。

Vaswani 等人^[38]受到 Attention 机制启发设计了 Transformer 模型，并提出只依靠 Attention 机制就能够有效提取序列数据特征。该模型主要由编码器和解码器组成，输入数据在经过多层感知机 (Multilayer Perceptron, MLP) 处理后被扩展成一定纬度的输入数据单元 (Token)，通过对 Token 和相关矩阵进行向量乘法可以得到三个关键向量，分别被称为 Q (Query) 向量、K (Key) 向量、V (Value) 向量。Transformer 的 Attention 操作增强了所有 Token 对自身的表示，也被称为自注意力 (Self-Attention) 机制，可被描述如下：对 Q 向量和转置后的 K 向量进行矩阵乘法，再除以对 Q、K 向量共同维度 d_k 开平方根后的结果，最后进行 softmax 操作得到两个向量间的相关度衡量权重，对 V 向量的放缩将以该相关度为依据。其中，通过除以 d_k 的平方根可以缩小相关度中各项的方差，使得内部元素分布更为平滑，从而在训练过程中保持梯度稳定，因此该量也被称为缩放因子。该过程可被表示为公式 (2-31)：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-31)$$

Transformer 在对该机制扩展得到多头自注意力 (Multi-head Self-Attention) 机制，进一步减少了 Attention 的计算复杂度。在该过程中，按照维度把被映射到高维空间后的 Token 拆分至子空间，并利用相关矩阵进行乘法运算分别获得 Q、K、V 向量，从而可以在子空间中进行计算，最后将所有 Attention 信息进行合并。由于各子空间中 Attention 的分布也不相同，因此该机制可被理解为尝试从不同角度探索序列关联，再通过向量拼接将所有关联进行整合统一的操作。

Transformer 的所有模块最后通常都会进行层归一化 (Layer Normalization, LN) 从而规范优化数据空间，加快模型收敛速度。同时，在 Attention 操作后，还会经过由两个线性层的 MLP，最后利用 ReLU 函数进行激活，从而增强模型表达能力。

Transformer 在提出之际主要被用于机器翻译任务。毫无疑问，在该应用场景中，文字输入顺序对翻译结果有很大影响。而 Attention 机制中认为 Token 的顺序不会改变最终结果。因此 Transformer 引入了特殊位置嵌入方法学习 Token 间的相对位置信息，如

公式 (2-32) 所示:

$$\begin{cases} PE(pos, 2i) = \sin(pos/10000^{2i/d_{model}}) \\ PE(pos, 2i+1) = \cos(pos/10000^{2i/d_{model}}) \end{cases} \quad (2-32)$$

式中: i ——向量元素在某一维度的向量中的位置序号; d_{model} ——维数

上述部分介绍了该模型的编码器部分。对于解码器,模型利用 Mask 操作使网络在训练时将后续信息进行遮盖,在输出时只会收到之前相邻列序位置的信息,确保了在翻译任务中将结果按序输出。

2.3 基于深度学习的域适应方法

深度神经网络近来在表示学习领域得到广泛的运用,这些网络能够从数据中提取出一般性的特征表征,显示出其强大的能力。但是,这种方法依赖于大量的标记数据进行训练,这一过程不仅成本高昂,耗时久,而且有时还难以实施。同时,神经网络通常假定训练和测试数据来自同一分布,但当存在域偏移时,模型性能可能会受到影响^[39],例如一个以真实图像数据训练的网络模型,在对同类别的动漫图像进行分类预测时,输出结果精度会大大降低。为了应对这些挑战,深度域适应技术应运而生,它利用深度网络的特性和适应策略来弥补标注数据不足的问题,并提升模型在新域上的表现。目前计算机视觉^[40]、自然语言处理^[41]、语音识别^[42]等众多领域都有深度域适应的工作产出。基于深度学习的域适应方法主要由三个类别组成:基于差异性 (Discrepancy-based)、基于重构 (Reconstruction-based) 和基于对抗 (Adversarial-based) 的方法。

2.3.1 基于差异性的深度域适应

这类方法致力于通过缩减源域与目标域之间的分布差距来实现域适应。顾名思义,基于差异性的深度域适应主要依赖于对不同域之间分布距离的度量,如最大均值差异 (MMD)、沃瑟斯坦距离 (Wasserstein distance) 等。该方法将深度模型分为两部分,特征提取器和分类器,分别用于提取数据特征分布和输出结果。模型训练过程如图 2-5 所示,主要最小化分类损失和基于差异性的损失。其中,分类损失对模型整体进行更新,以提升预测性能,基于差异性的损失通过更新特征提取器参数从而减小域间分布距离,从而使模型生成与源域相似的目标域特征。



图 2-5 基于差异性的深度域适应训练过程示意图

Long 等人^[43]提出的深度自适应网络 (Deep Adaptation Network, DAN) 便是该类方法的一个代表, 它在多个特定任务的调整层使用 MMD 的相关变种 MK-MMD (Multi Kernel-Maximum Mean Discrepancy), 以此衡量和对准不同域的边缘分布。该方法假设虽然边缘分布存在偏差, 但是条件分布保持一致, 因此主要通过调整层对源域和目标域的边缘分布进行匹配, 而不会直接对条件分布差异进行调整。Zhang 等人^[44]提出深度迁移网络 (Deep Transfer Network, DTN) 利用 MMD 进行对齐, 但其通过结合共享特征提取层和类别转换层来将边缘分布和条件分布同时对齐, 实现了更为精细的域适应。

2.3.2 基于重构的深度域适应

这类方法的核心思想是最小化重构误差来对齐源域和目标域之间的分布差异, 即让模型学习从目标域图像转换到源域图像。模型方面主要由编码器-解码器网络和分类器组成。图 2-6 展示了基于重构的深度域适应常规训练过程, 首先训练一个编码器以获取数据中共通的特征表示, 再部署对应解码器学习将编码器的特征重构, 同时利用源数据训练分类器实现基于源域的分类预测, 从而提高了模型在目标域上的泛化能力。



图 2-6 基于重构的深度域适应训练过程示意图

Ghifary 等人^[45]结合 CNN 架构提出深度重建分类网络 (Deep Reconstruction Classification Networks, DRCN), 该方法联合了监督学习和无监督学习策略, 在编码器后设置两个管道分别用于分类和数据重构, 使编码器参数在两个任务中共享, 而解码器参数单独用于数据重构任务, 以此加强了标签预测的准确性。Bousmalis 等人^[46]设计的域分离网络 (Domain Separation Network, DSN) 在共享编码器的基础上分别为源域和目标域设置了私有的编码器, 最后使用公有解码器重构数据和提供特征训练源域分类器, 这种为各域建模的方式提高了模型学习域不变特征的能力。

2.3.3 基于对抗的深度域适应

该类方法受到生成对抗网络 (Generative Adversarial Networks, GAN) 的启发, 旨在通过特征提取器和域判别器之间的对抗学习来优化模型。基于对抗的深度域适应训练过程如图 2-7 所示, 特征提取器用于提取目标域数据信息, 生成混淆域判别器的域不变特征, 域判别器则判别特征属于源域还是目标域, 分类器则用于判定标签类别, 整体训练直到真假难辨为止。



图 2-7 基于重构的深度域适应训练过程示意图

Ganin 等人^[47]首先将对抗训练思想运用到深度域适应中, 设置梯度反转层 (GRL) 来对齐源域和目标域之间差距, 通过负标量和梯度相乘实现反转, 使模型在域间特征相似的情况下有效进行对抗训练。Tzeng 等人^[48]则并未使用参数共享机制, 通过最小化模型各部分的损失函数来学习更多领域独有的有特征, 从而有效缩小源域和目标域的差距。Pei^[49]考虑到许多该类方法中的单一域鉴别器存在鉴别组件自身混淆的隐患, 设计了多鉴别器结构, 从而实现类别水平上域间差距的细粒度对齐。

3 基于目标特征搜寻的无源域适应方法

3.1 引言

4 基于联邦学习的无源域适应方法

4.1 引言

5 非正文部分的要求

6 本模板已载入的 Packages

致 谢

致谢中主要感谢导师和对论文工作有直接贡献和帮助的人士和单位。一般致谢的内容有：

- (一) 对指导或协助指导完成论文的导师；
- (二) 对国家自然科学基金、资助研究工作的奖学金基金、合同单位、资助或支持的企业、组织或个人；
- (三) 对协助完成研究工作和提供便利条件的组织或个人；
- (四) 对在研究工作中提出建议和提供帮助的人；
- (五) 对给予转载和引用权的资料、图片、文献、研究思想和设想的所有者；
- (六) 对其他应感谢的组织和个人。

致谢言语应谦虚诚恳，实事求是。字数不超过 1000 汉字

用于双盲评审的论文，此页内容全部隐去。

参考文献

- [1] ZHANG J, XI R, HE Y, et al. A survey of mmWave-based human sensing: Technology, platforms and applications[J]. IEEE Communications Surveys & Tutorials, 2023.
- [2] LI H, SHRESTHA A, HEIDARI H, et al. Bi-LSTM network for multimodal continuous human activity recognition and fall detection[J]. IEEE Sensors Journal, 2019, 20(3): 1191-1201.
- [3] AN S, OGRAS U Y. Mars: mmwave-based assistive rehabilitation system for smart healthcare[J]. ACM Transactions on Embedded Computing Systems (TECS), 2021, 20(5s): 1-22.
- [4] LIU H, WANG Y, ZHOU A, et al. Real-time arm gesture recognition in smart home scenarios via millimeter wave sensing[J]. Proceedings of the ACM on interactive, mobile, wearable and ubiquitous technologies, 2020, 4(4): 1-28.
- [5] LIU X, YOO C, XING F, et al. Deep unsupervised domain adaptation: A review of recent advances and perspectives[J]. APSIPA Transactions on Signal and Information Processing, 2022, 11(1).
- [6] XU M, ZHANG J, NI B, et al. Adversarial domain adaptation with domain mixup[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 34: 04. 2020: 6502-6509.
- [7] ZHU J Y, PARK T, ISOLA P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.
- [8] YANG J, LIU J, XUN N, et al. Tvt: Transferable vision transformer for unsupervised domain adaptation [C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2023: 520-530.
- [9] HAN J, LUO P, WANG X. Deep self-learning from noisy labels[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 5138-5147.
- [10] JIN Y, WANG X, LONG M, et al. Minimum class confusion for versatile domain adaptation[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXI 16. 2020: 464-480.
- [11] LIANG J, HU D, FENG J. Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation[C]//International conference on machine learning. 2020: 6028-6039.
- [12] XIA H, ZHAO H, DING Z. Adaptive adversarial network for source-free domain adaptation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 9010-9019.
- [13] DING N, XU Y, TANG Y, et al. Source-free domain adaptation via distribution estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 7212-7222.
- [14] VENKATESWARA H, EUSEBIO J, CHAKRABORTY S, et al. Deep hashing network for unsupervised domain adaptation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 5018-5027.
- [15] SAKARIDIS C, DAI D, GOOL L V. Guided curriculum model adaptation and uncertainty-aware

- evaluation for semantic nighttime image segmentation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 7374-7383.
- [16] SAKARIDIS C, DAI D, VAN GOOL L. ACDC: The adverse conditions dataset with correspondences for semantic driving scene understanding[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10765-10775.
- [17] TAN S, YANG J. WiFinger: Leveraging commodity WiFi for fine-grained finger gesture recognition[C]//Proceedings of the 17th ACM international symposium on mobile ad hoc networking and computing. 2016: 201-210.
- [18] YANG J, ZOU H, JIANG H, et al. Fine-grained adaptive location-independent activity recognition using commodity WiFi[C]//2018 IEEE Wireless Communications and Networking Conference (WCNC). 2018: 1-6.
- [19] LI S, LI X, LV Q, et al. WiFit: Ubiquitous bodyweight exercise monitoring with commodity wi-fi devices[C]//2018 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCCom/IOP/SCI). 2018: 530-537.
- [20] JIANG W, MIAO C, MA F, et al. Towards environment independent device free human activity recognition[C]//Proceedings of the 24th annual international conference on mobile computing and networking. 2018: 289-304.
- [21] DING S, CHEN Z, ZHENG T, et al. RF-net: A unified meta-learning framework for RF-enabled one-shot human activity recognition[C]//Proceedings of the 18th Conference on Embedded Networked Sensor Systems. 2020: 517-530.
- [22] BHALLA S, GOEL M, KHURANA R. Imu2doppler: Cross-modal domain adaptation for doppler-based activity recognition using imu data[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2021, 5(4): 1-20.
- [23] ZHOU Z, WANG F, YU J, et al. Target-oriented semi-supervised domain adaptation for WiFi-based HAR[C]//IEEE INFOCOM 2022-IEEE Conference on Computer Communications. 2022: 420-429.
- [24] WANG X, KONG L, KONG F, et al. Millimeter wave communication: A comprehensive survey[J]. IEEE Communications Surveys & Tutorials, 2018, 20(3): 1616-1653.
- [25] LIU J, ZHAO Q, XIONG W, et al. SMURF: Spatial multi-representation fusion for 3D object detection with 4D imaging radar[J]. IEEE Transactions on Intelligent Vehicles, 2023.
- [26] ROOS F, BECHTER J, KNILL C, et al. Radar sensors for autonomous driving: Modulation schemes and interference mitigation[J]. IEEE Microwave Magazine, 2019, 20(9): 58-72.
- [27] MORRIS P J B, HARI K. Detection and localization of unmanned aircraft systems using millimeter-wave automotive radar sensors[J]. IEEE Sensors Letters, 2021, 5(6): 1-4.
- [28] SONG M, LIM J, SHIN D J. The velocity and range detection using the 2D-FFT scheme for automotive radars[C]//2014 4th IEEE International Conference on Network Infrastructure and Digital Content. 2014: 507-510.
- [29] GHOLAMALINEZHAD H, KHOSRAVI H. Pooling methods in deep neural networks, a review[J].

- arXiv preprint arXiv:2009.07485, 2020.
- [30] IOFFE S, SZEGEDY C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. 2015: 448-456.
 - [31] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014, 15(1): 1929-1958.
 - [32] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
 - [33] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
 - [34] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
 - [35] LIN M, CHEN Q, YAN S. Network in network[J]. arXiv preprint arXiv:1312.4400, 2013.
 - [36] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
 - [37] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
 - [38] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
 - [39] FARAHANI A, VOGHOEI S, RASHEED K, et al. A brief review of domain adaptation[J]. Advances in data science and information engineering: proceedings from ICDATA 2020 and IKE 2020, 2021: 877-894.
 - [40] CHEN Y, LI W, SAKARIDIS C, et al. Domain adaptive faster r-cnn for object detection in the wild [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 3339-3348.
 - [41] GUO H, PASUNURU R, BANSAL M. Multi-source domain adaptation for text classification via distancenet-bandits[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 34: 05. 2020: 7830-7838.
 - [42] SUN S, ZHANG B, XIE L, et al. An unsupervised deep domain adaptation approach for robust speech recognition[J]. Neurocomputing, 2017, 257: 79-87.
 - [43] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C] //International conference on machine learning. 2015: 97-105.
 - [44] ZHANG X, YU F X, CHANG S F, et al. Deep transfer network: Unsupervised domain adaptation [J]. arXiv preprint arXiv:1503.00591, 2015.
 - [45] GHIFARY M, KLEIJN W B, ZHANG M, et al. Deep reconstruction-classification networks for unsupervised domain adaptation[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14. 2016: 597-613.
 - [46] BOUSMALIS K, TRIGEORGIS G, SILBERMAN N, et al. Domain separation networks[J]. Advances in neural information processing systems, 2016, 29.
 - [47] GANIN Y, LEMPITSKY V. Unsupervised domain adaptation by backpropagation[C]//International

- conference on machine learning. 2015: 1180-1189.
- [48] TZENG E, HOFFMAN J, SAENKO K, et al. Adversarial discriminative domain adaptation[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7167-7176.
- [49] PEI Z, CAO Z, LONG M, et al. Multi-adversarial domain adaptation[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 32: 1. 2018.

附录 A 公式推导

A.1 第一章

附录编号依次编为附录 A, 附录 B。附录标题各占一行, 按一级标题编排。每一个附录一般应另起一页编排, 如果有多个较短的附录, 也可接排。附录中的图表公式另行编排序号, 与正文分开, 编号前加“附录 A-”字样。

本部分内容非强制性要求, 如果论文中没有附录, 可以省略《附录》。

定义 附录 A.1 (向量空间) 设 X 是一个非空集合, \mathbb{F} 是一个数域 (实数域 \mathbb{R} 或者复数域 \mathbb{C})。如果在 X 上定义了加法和数乘两种运算, 并且满足以下 8 条性质:

1. 加法交换律, $\forall x, y \in X, x + y = y + x \in X$;
2. 加法结合律, $\forall x, y, z \in X, (x + y) + z = x + (y + z)$;
3. 加法的零元, $\exists 0 \in X$, 使得 $\forall x \in X, 0 + x = x$;
4. 加法的负元, $\forall x \in X, \exists -x \in X$, 使得 $x + (-x) = x - x = 0$ 。
5. 数乘结合律, $\forall \alpha, \beta \in \mathbb{F}, \forall x \in X, (\alpha\beta)x = \alpha(\beta x) \in X$;
6. 数乘分配律, $\forall \alpha \in \mathbb{F}, \forall x, y \in X, \alpha(x + y) = \alpha x + \alpha y$;
7. 数乘分配律, $\forall \alpha, \beta \in \mathbb{F}, \forall x \in X, (\alpha + \beta)x = \alpha x + \beta x$;
8. 数乘的幺元, $\exists 1 \in \mathbb{F}$, 使得 $\forall x \in X, 1x = x$,

例子 附录 A.2 (矩阵空间) 所有 $m \times n$ 的矩阵在普通矩阵加法和矩阵数乘运算下构成一个向量空间 $\mathbb{C}^{m \times n}$ 。如果定义内积如下:

$$\langle A, B \rangle = \text{tr}(B^H Q A) = \sum_{i=1}^n b_i^H Q a_i \quad (\text{附录 A-1})$$

其中 a_i 和 b_i 分别是 A 和 B 的第 i 列, 而 Q 是 Hermite 正定矩阵, 那么 $\mathbb{C}^{m \times n}$ 构成一个 Hilbert 空间。

定理 附录 A.3 (Riesz 表示定理) 设 H 是 Hilbert 空间, H^* 是 H 的对偶空间, 那么对 $\forall f \in H^*$, 存在唯一的 $x_f \in H$, 使得

$$f(x) = \langle x, x_f \rangle, \quad \forall x \in H \quad (\text{附录 A-2})$$

并且满足 $\|f\| = \|x_f\|$ 。

证明: 先证存在性, 再证唯一性, 最后正 $\|f\| = \|x_f\|$ 。 ■

附录 B 附录图表

附录 B-表 1 左对齐

Symptom	Metric
Class that has many accessor methods and accesses a lot of external data	ATFD is more than a few
Class that is large and complex	WMC is high
Class that has a lot of methods that only operate on a proper subset of the instance variable set	TCC is low



(a) 蓝色校徽



(b) 还是蓝色校徽

附录 B-图 1 校徽

附录 B-表 2 居中

Symptom	Metric
Class	ATFD
Class	WMC
Class	TCC

攻读学位期间取得的研究成果

- [1] Wei ZY, Tang YP, Zhao WH, et al. Rapid development technique for drip irrigation emitters[J]. RP Journal,UK., 2003, 9(2):104 110 (SCI: 000350930600051; EI: 03187452127).
- [2] 魏正英, 唐一平, 卢秉恒. 滴灌管内嵌管状滴头的快速制造方法研究 [J]. 农业工程学报, 2001,17(2):55 58 (EI:01226526279,01416684777).
- [3]
- [4]
- [5]
- [6]
- [7]
- [8]
- [9]
- [10]
- [11]
- [12]
- [13]
- [14]
- [15]
- [16]
- [17]
- [18]
- [19]
- [20]
- [21]
- [22]
- [23]
- [24]
- [25]

用于双盲评审的论文，只列出已发表的学术论文的篇名、发表刊物名称，必须隐去各类论文检索号、期号、卷号、页码；专利号；日期等。

答辩委员会会议决议

论文提出了受经更奇小极准。形程记持件志各质天因时，据据极清总命所风式，气太束书家秀低坟也。期之才引战对已公派及济，间究办儿转情革统将，周类弦具调除声坑。两了济素料切要压，光采用级数本形，管县任其坚。切易表候完铁今断土马他，领先往样拉口重把处千，把证建后苍交码院眼。较片的集节片合构进，入化发形机已斯我候，解肃飞口严。技时长次土员况属写，器始维期质离色，个至村单原否易。重铁看年程第则于去，且它后基格并下，每收感石形步而。

论文取得的主要创新性成果包括：

1. 水厂共当而面三张，白家决空给意层般，单重总歼者新。每建马先口住月大，究平克满现易手，省否何安苏京。两今此叫证程事元七调联派业你，全它精据间属医拒严力步青。厂江内立拉清义边指，况半严回和得话，状整度易芬列。再根心应得信飞往清增，至例联集采家同严热，地手蠢持查受立询。统定发几满斯究后参边增消与内关，解系之展习历李还也村酸。制周心值示前她志长步反，和果使标电再主它这，即务解旱八战根交。是中文之象万影报头，与劳工许格主部确，

2. 受经更奇小极准。形程记持件志各质天因时，据据极清总命所风式，气太束书家秀低坟也。期之才引战对已公派及济，间究办儿转情革统将，周类弦具调除声坑。两了济素料切要压，光采用级数本形，管县任其坚。切易表候完铁今断土马他，领先往样拉口重把处千，把证建后苍交码院眼。较片的集节片合构进，入化发形机已斯我候，解肃飞口严。技时长次土员况属写，器始维期质离色，个至村单原否易。重铁看年程第则于去，且它后基格并下，每收感石形步而

论文工作表明作者在×××××具有×××××知识,具有×××××能力,论文××××××××××,答辩××××××××××××××。

答辩委员会表决，(×票/一致)同意通过论文答辩，并建议授予×××(姓名)×××(门类)学博士/硕士学位。

常规评阅人名单

本学位论文共接受 7 位专家评阅，其中常规评阅人 5 名，名单如下：

张长长	教授	西安交通大学
王旺旺	教授	西安理工大学
李力	高工	国网陕西经济技术研究院
东方不败	副教授	西安交通大学
赵照	研究员	西安交通大学

学位论文独创性声明 (1)

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉。
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者 (签名): _____ 日期: _____ 年 _____ 月 _____ 日

学位论文独创性声明 (2)

本人声明：研究生_____所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉。
3. 本人接受学校按照有关规定做出的任何处理。

指导教师（签名）： 日期： 年 月 日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者（签名）： 日期： 年 月 日

指导教师（签名）： 日期： 年 月 日

(本声明的版权归西安交通大学所有, 未经许可, 任何单位及任何个人不得擅自使用)